Tarea 02: Implementación de Regresión Lineal Manual con Descenso de Gradiente

Curso de Inteligencia Artificial
Escuela de Ingeniería en Computación
Instituto Tecnológico de Costa Rica

I. Objetivo

El propósito de esta tarea es implementar y analizar un modelo de regresión lineal desde cero utilizando únicamente NumPy y Pandas, aplicándolo al conjunto de datos Student Performance Prediction disponible en Kaggle.

Se espera que el estudiante realice un análisis exploratorio detallado de las características del conjunto de datos y la variable a predecir, que implemente algoritmos de división del (random sampling y stratified sampling), ajuste un modelo de regresión lineal utilizando descenso del gradiente calculado manualmente y evalúe el modelo con métricas implementadas manualmente.

II. Pasos a seguir

A. Descarga del Conjunto de Datos

Descargar el dataset desde el siguiente enlace: Kaggle

B. Lectura del Dataset

- Utilizar Pandas para cargar el dataset en un DataFrame.
- Explorar la estructura del dataset (filas, columnas, tipos de variables).
- Obtener estadísticas descriptivas: media, desviación estándar, valores mínimos y máximos.

C. Análisis de Características

Realizar un análisis exploratorio de datos (EDA) que incluya:

- • Realizar un análisis exploratorio de datos (EDA): histogramas y boxplots de variables numéricas, diagramas de dispersión entre características y el target, matriz de correlación (con mapa de calor), o cualquier visualización que considere necesaria.
- Identificar y reportar datos sobresalientes en caso de existir, y aplicarles tratamiento. Caso contrario debe justificar que o hay presencia de datos sobresalientes

El análisis debe incluir no solo visualizaciones, sino también interpretación de los resultados.

D. División del Dataset

Implementar manualmente:

1) **Muestreo aleatorio (Random Sampling).**

El conjunto de datos debe dividirse en 70% entrenamiento, 15% validación y 15% prueba. No está permitido el uso de funciones de `scikit-learn` como `train_test_split`.

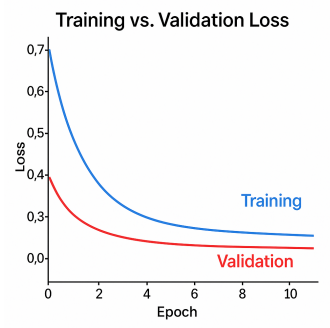

Fig. 1. Training vs Loss sample

E. Implementación de Regresión Lineal

- Implementar la regresión lineal con NumPy utilizando **descenso del gradiente**. Los parámetros β deben actualizarse manualmente con la regla:

$$\theta := \theta - \alpha \cdot \nabla L(\beta)$$

  donde α es la tasa de aprendizaje y $\nabla L(\theta)$ es el gradiente de la función de costo.
- El estudiante debe implementar dos experimentos, uno con Batch Gradient Descent (**A**), y el otro con Mini Batch Gradient (**B**) para comparar los resultados.

F. Evaluación del Modelo

Calcular manualmente las siguientes métricas:

- Error cuadrático medio (MSE)
- Debe de visualizar los resultados del MSE por cada actualización de pesos. Y comparar el training y validation para detectar overfitting Ver Figura 1.

G. Análisis de Resultados

- Se espera que cada experimento (**A**) y (**B**) se ejecute al menos 10 veces con distintos hiperparámetros. Para cada ejecución se debe de usar el modelo entrenado y correrlo con el conjunto de datos de test. Debe calcular el MSE para su conjunto de test y hacer una tabla comparativa entre todas las ejecuciones realizadas para determinar cual fué el mejor modelo entrenado.
- Genere un gráfico de residuos vs predicciones con su mejor modelo, y establezca un análisis final.

H. Entrega

El informe deberá realizarse en LaTeX (Overleaf) utilizando la plantilla IEEE para artículos científicos. El documento debe contener visualizaciones, y la interpretación de los resultados. Además, se debe adjuntar un **Jupyter Notebook** con el código implementado. La entrega final consistirá en un archivo comprimido (`.zip`) que contenga:

- Código fuente en LaTeX.
- El PDF del informe.
- El Notebook con el código fuente.

RÚBRICA

Criterio	**Puntaje Máx.**
Descarga y lectura del dataset	10
Análisis exploratorio y outliers	25
División (aleatoria)	15
Regresión lineal con gradiente	25
Métricas manuales	15
Presentación de resultados	10
Total	**100**

Si el trabajo no se encuentra debidamente ordenado y presentado siguiendo una adecuada estructura para el informe, puede ser considerado como incompleto y cualquiera de las rúbricas se puede ver afectada.